

Лабораторная работа №1
студента группы ИТ – 32
Курбатовой Софьи Андреевны

Выполнение: _____ Защита _____

РЕАЛИЗАЦИЯ АЛГОРИТМОВ ПОИСКА ПО ТЕКСТУ.

Цель работы: научиться реализовывать на выбранном языке программирования алгоритмы поиска по тексту: прямой поиск; алгоритм Кнута, Морриса и Пратта; алгоритм Бойера-Мура.

Содержание работы

Написать программу на выбранном языке программирования, реализующую указанные выше алгоритмы для поиска подстроки в строке. Программа должна запрашивать имя входного файла. Оценить трудоемкость рассматриваемых алгоритмов.

Ход работы

1. Идея состоит в следующем: перебрать текст и, если есть совпадение для первой буквы шаблона, проверит, все ли буквы шаблона соответствуют тексту. Если m - это количество букв в шаблоне, а n - это количество букв в тексте, временная сложность этих алгоритмов равна $O(m(n-m+1))$.

Листинг 1.1. Функция реализующая алгоритм простого поиска.

```
#include <iostream>
#include <string>
#include <cstring>
#include <iostream>
#include <fstream>
#include <stdio.h>
#define _CRT_SECURE_NO_WARNINGS
char* userStrstr(const char* haystack, char* needle)
{
    for (const char* hp = haystack; hp != haystack + strlen(haystack); ++hp)
    {
        const char* np = needle;
        const char* tmp = hp;
        for (; np != needle + strlen(needle); ++np)
        {
            if (*tmp != *np)
            {
                break;
            }
            else
            {
                ++tmp;
            }
        }
        if (np == needle + strlen(needle))
        {
            std::cout << "Прямой поиск: Найдено на " << pos+1 << "позиции от начала строки\n";
            return needle;
        }
    }
    return 0;
}
```

Преимущество этого алгоритма в том, что ценой некоторого количества предварительных вычислений над шаблоном (но не над строкой, в которой ведётся поиск), шаблон сравнивается с исходным текстом не во всех позициях — часть проверок пропускаются как заведомо не дающие результата.

Общая оценка вычислительной сложности современного варианта алгоритма Бойера — Мура — $O(n+m)$, где n — длина строки, в которой выполняется поиск, m — длина шаблона поиска.

Листинг 1.2. Функция реализующая алгоритм Бойера-Мура.

```
int BMSearch(char* str, char* substr)
{
    int sl, ssl;
    int res = -1;
    sl = strlen(str);
    ssl = strlen(substr);
    int i, Pos;
    int BMT[256];
    for (i = 0; i < 256; i++)
        BMT[i] = ssl;
    for (i = ssl - 1; i >= 0; i--)
        if (BMT[(short)substr[i]] == ssl)
            BMT[(short)(substr[i])] = ssl - i - 1;
    Pos = ssl - 1;
    while (Pos < sl)
        if (substr[ssl - 1] != str[Pos])
            Pos = Pos + BMT[(short)str[Pos]];
        else
            for (i = ssl - 2; i >= 0; i--) {
                if (substr[i] != str[Pos - ssl + i + 1]) {
                    Pos += BMT[(short)(str[Pos - ssl + i + 1])] - 1;
                    break;
                }
            }
            else if (i == 0)
                return Pos - ssl + 1;
    return res;
}
```

Идея алгоритма Кнута-Морриса-Пратта заключается в расчете таблицы сдвигов, которая предоставляет нам информацию, в которой мы должны искать кандидатов-паттернов.

Листинг 1.3. Функция реализующая алгоритм Кнута, Морриса, Пратта.

```
int KMPSearch(char* str, char* substr)
{
    int sl, ssl;
    int res = -1;
    sl = strlen(str);
    ssl = strlen(substr);
    int i, j = 0, k = -1;
    int* d;
    d = new int[1000];
    d[0] = -1;
    while (j < ssl - 1) {
        while (k >= 0 && substr[j] != substr[k])
            k = d[k];
        j++;
        k++;
        if (substr[j] == substr[k])
            d[j] = d[k];
        else
            d[j] = -1;
    }
    return res;
}
```

```

        d[j] = k;
    }
    i = 0;
    j = 0;
    while (j < ssl && i < sl) {
        while (j >= 0 && str[i] != substr[j])
            j = d[j];
        i++;
        j++;
    }
    delete[] d;
    res = j == ssl ? i - ssl : -1;
    std::cout << "Алгоритм Кнута, Морриса и Пратта: Найдено на "<<i-ssl+1<<" позиции от начала
строки\n";
    return res;
}

```

Листинг 1.4. Главная функция

```

int main()
{
    setlocale(LC_ALL, "");
    //char path = "C:\\test\\tests.txt";
    char path[100];
    char line[100];
    char search[100];
    std::cout << "Enter path:\t";
    std::cin >> path;
    std::cout << "Enter search word:\t";
    std::cin >> search;
    std::ifstream input(path);

    while (!input.is_open())
    {
        std::cerr << "File error" << std::endl;
        std::cin.ignore();
        break;
    }
    if (input)
    {
        while (!input.eof())
        {
            input.getline(line, 80);
            std::cout << "Символов в строке-источнике: " << strlen(line) << ". Символов в
искомой строке: " << strlen(search) << std::endl;
            if (userStrstr(line, search))
            {
                std::cout << "Прямой поиск:" << std::endl;
                std::cout << "Сложность = "<< ((strlen(line) -
strlen(search)+1)*strlen(search)) <<std::endl;
                std::cout <<"Your word: " <<search << " in "<<"' " <<line<<"
'"<<std::endl;
            }

            if (KMPSearch(line, search)!= -1)
            {
                std::cout << "Алгоритм Кнута, Морриса и Пратта:" << std::endl;
                std::cout << "Сложность = " << (strlen(line) + strlen(search))
<<std::endl;

                std::cout << "Your word: " << search << " in " << "' " << line << " '"
<< std::endl;
            }
            if (BMSearch(line, search)!= -1)
            {
                std::cout << "Алгоритм Бойера-Мура:" << std::endl;
                std::cout << "Сложность = " << (strlen(line) + strlen(search)) <<
std::endl;
            }
        }
    }
}

```

```

std::cout << "Your word: " << search << " in " << " " << line << " "
<< std::endl;
    }
}
input.close();
}

```

2. Тестирование:




Рис. 1.1. Исходный текстовый файл

```

Enter path:      C:\\test\\tests.txt
Enter search word:      where
Символов в строке-источнике: 22. Символов в искомой строке: 5
Символов в строке-источнике: 20. Символов в искомой строке: 5
Прямой поиск:
Сложность = 80
Your word: where in ' ktulhu where bullets '
Алгоритм Кнута, Морриса и Пратта:
Сложность = 25
Your word: where in ' ktulhu where bullets '
Алгоритм Бойера-Мура:
Сложность = 25
Your word: where in ' ktulhu where bullets '

```

Рис. 1.2. Результат работы программы

```

Выбрать Консоль отладки Microsoft Visual Studio
Enter path:      C:\test\tests.txt
Enter search word:      text
Символов в строке-источнике: 22. Символов в искомой строке: 4

Прямой поиск: Найдено на 6 позиции от начала строки
Сложность = 76
Your word: text in ' Test text about ktulhu '

Алгоритм Кнута, Морриса и Пратта: Найдено на 6 позиции от начала строки
Сложность = 26
Your word: text in ' Test text about ktulhu '

Алгоритм Бойера-Мура: Найдено на 6 позиции от начала строки
Сложность = 26
Your word: text in ' Test text about ktulhu '
Символов в строке-источнике: 20. Символов в искомой строке: 4

```

Рис. 1.3. Результат работы программы с указанием позиции

Вывод: Таким образом, в ходе выполнения лабораторной работы на языке C/C++ были реализованы алгоритмы поиска строки, задаваемой пользователем, в текстовом файле, путь к которому также задается пользователем. Была проведена оценка сложности используемых алгоритмов. В результате было выявлено, что наиболее эффективными можно считать алгоритмы Кнута и Бойера-Мура, так как их сложность $O(m+n)$. С другой стороны, наиболее понятен и быстро реализуем, так как

не требует дополнительной обработки текста, алгоритм простого поиска. Однако он сложнее: $O((n-m+1)*m)$. Потому что, искомая строка сравнивается посимвольно.